



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ Информатики и систем управления

КАФЕДРА Теоретической информатики и компьютерных технологий

Лабораторная работа №6

“Градиентный спуск”

ПО КУРСУ:

«Методы оптимизация»

Студент ИУ9-82Б Потребина В. В.

Преподаватель Посевин Д. П.

Москва, 2024 г.

ОГЛАВЛЕНИЕ

1. Цели	3
2. Практическая реализация	3
3. Результаты	8
4. Выводы	9

1. Цели

Цель данной лабораторной работы — **реализовать и исследовать методы градиентной оптимизации** для нахождения минимума функций.

Рассматриваются три метода:

1. Метод градиентного спуска (Gradient Descent, GD)

- Движение в направлении **отрицательного градиента** с фиксированным шагом.
- Используется **адаптивное уменьшение шага**, если функция не уменьшается.

2. Метод наискорейшего спуска (Steepest Descent, SD)

- Подбор **оптимального шага α** на каждом шаге **методом золотого сечения**.
- Позволяет **быстрее сходиться**, но требует дополнительных вычислений.

3. Метод сопряжённых градиентов (Conjugate Gradient, CG)

- Улучшает стандартный градиентный спуск, **учитывая прошлые направления**.
- Сходится **значительно быстрее** на квадратичных функциях.

Исследуется **сходимость** каждого метода на **различных тестовых функциях**.

2. Практическая реализация

```
using Plots

function norm(p)
    return sqrt(sum(p .* p))
end

# Функция для численного вычисления градиента методом конечных разностей
function numerical_gradient(f, x, h=1e-5)
    grad = zeros(length(x))
    for i in eachindex(x)
        x_step = copy(x)
        x_step[i] += h
        grad[i] = (f(x_step) - f(x)) / h
    end
end
```

```

    return grad
end

# Метод золотого сечения для одномерной оптимизации
function golden_section_search(f, a, b, tol=1e-5)
    φ = (sqrt(5) - 1) / 2 # Коэффициент золотого сечения
    c = b - (b - a) * φ
    d = a + (b - a) * φ
    while abs(b - a) > tol
        if f(c) < f(d)
            b = d
        else
            a = c
        end
        c = b - (b - a) * φ
        d = a + (b - a) * φ
    end
    return (a + b) / 2 # Оптимальное значение α
end

function gradient_descent(f, x0; α=0.1, tol_x=1e-5, tol_f=1e-5, maxiter=1000)
    x = x0 # Текущая точка
    history = [x] # История точек
    α_init = α # Сохраняем начальный шаг

    for k in 1:maxiter
        g = numerical_gradient(f, x) # Вычисляем градиент вручную

        if norm(g) < tol_f # Проверка  $||\nabla f(x)|| \leq \epsilon_3$ 
            println("Метод сошелся по норме градиента на $k итерации")
            break
        end

        x_new = x - α * g # Градиентный шаг

        # Откат шага, если  $f(x_{\text{new}}) \geq f(x)$ 
        while f(x_new) >= f(x)
            α /= 2 # Уменьшаем шаг
            x_new = x - α * g
        end

        # Условие остановки по изменениям
        if norm(x_new - x) < tol_x || abs(f(x_new) - f(x)) < tol_f
            println("Метод сошелся по критериям остановки на $k итерации")
            break
        end

        x = x_new
        α = α_init # Сбрасываем α к начальному значению
    end
end

```

```

        push!(history, x)
    end

    return x, history
end

# Метод наискорейшего спуска
function steepest_descent(f, x0; tol=1e-5, maxiter=500)
    x = x0
    history = [x]

    for k in 1:maxiter
        g = numerical_gradient(f, x)

        if norm(g) < tol
            println("Метод сошелся по градиенту на $k итерации")
            break
        end

        # Ограничиваем диапазон поиска  $\alpha$ 
         $\alpha_{\text{func}}(\alpha) = f(x - \alpha * g)$ 
         $\alpha_{\text{opt}} = \text{golden\_section\_search}(\alpha_{\text{func}}, 1e-4, 1)$ 

        x_new = x -  $\alpha_{\text{opt}} * g$ 

        if norm(x_new - x) < tol
            println("Метод сошелся по изменениям координат на $k итерации")
            break
        end

        x = x_new
        push!(history, x)
    end

    return x, history
end

# Метод сопряженных градиентов
function conjugate_gradient(f, x0; tol=1e-5, maxiter=1000)
    x = x0
    history = [x]

    g = numerical_gradient(f, x)
    p = -g

    for k in 1:maxiter
        if norm(g) < tol
            println("Метод сопряженных градиентов сошелся на $k итерации")
        end
    end
end

```

```

        break
    end

    # Оптимальный шаг  $\alpha$ 
     $\alpha_{\text{func}}(\alpha) = f(x + \alpha * p)$ 
     $\alpha_{\text{opt}} = \text{golden\_section\_search}(\alpha_{\text{func}}, 0, 1)$ 

     $x_{\text{new}} = x + \alpha_{\text{opt}} * p$ 
     $g_{\text{new}} = \text{numerical\_gradient}(f, x_{\text{new}})$ 

    if norm( $x_{\text{new}} - x$ ) < tol
        println("Метод сошелся по изменениям координат на $k итерации")
        break
    end

    # Коэффициент  $\beta$ 
     $\beta = (\text{norm}(g_{\text{new}})^2) / (\text{norm}(g)^2)$ 
     $p = -g_{\text{new}} + \beta * p$ 

     $x, g = x_{\text{new}}, g_{\text{new}}$ 
    push!(history,  $x$ )
end

return  $x, \text{history}$ 
end

# Целевые функции для тестирования
function target_quadratic( $x$ )
    return  $x[1]^2 + 2*x[2]^2$ 
end

function target_rosenbrock( $x$ )
    return  $(1 - x[1])^2 + 100 * (x[2] - x[1]^2)^2$ 
end

# Функция для визуализации траектории спуска
function plot_descent( $f, \text{history}; \text{xmin}=-2, \text{xmax}=2, \text{ymin}=-2, \text{ymax}=2$ )
     $x = \text{range}(\text{xmin}, \text{xmax}, \text{length}=100)$ 
     $y = \text{range}(\text{ymin}, \text{ymax}, \text{length}=100)$ 
     $Z = [f([xi, yi]) \text{ for } xi \text{ in } x, yi \text{ in } y]$ 

    plt = contour( $x, y, Z, \text{levels}=30, \text{title}=\text{"Траектория метода"}$ )
    traj_x = [ $p[1]$  for  $p$  in history]
    traj_y = [ $p[2]$  for  $p$  in history]

    plot!(plt, traj_x, traj_y, marker=:circle, color=:red, linewidth=2,
label="Траектория")
    display(plt)
end

```

```

# Универсальная функция для тестирования методов
function optimize_func(func, title="")
    if !isempty(title)
        println("===== $title =====")
    end

    x0 = [-1.5, 1.5] # Начальная точка

    # Запуск методов
    (final_gd, history_gd) = gradient_descent(func, x0) # Градиентный спуск
    (final_sd, history_sd) = steepest_descent(func, x0) # Наискорейший спуск
    (final_cg, history_cg) = conjugate_gradient(func, x0) # Сопряженные градиенты

    # Вывод результатов
    println("Gradient Descent: k = $(length(history_gd)) x_min =
$(final_gd) f(x_min) = ", func(final_gd))
    println("Steepest Descent: k = $(length(history_sd)) x_min =
$(final_sd) f(x_min) = ", func(final_sd))
    println("Conjugate Gradient: k = $(length(history_cg)) x_min =
$(final_cg) f(x_min) = ", func(final_cg))
    println("=====\n")

    # Определяем одинаковые границы для осей
    xmin, xmax = -2, 2
    ymin, ymax = -2, 2

    # --- Создание трех графиков ---
    plt1 = contour(range(xmin, xmax, length=100), range(ymin, ymax, length=100),
        [func([xi, yi]) for xi in range(xmin, xmax, length=100), yi in
range(ymin, ymax, length=100)],
        levels=30, title="Gradient Descent", aspect_ratio=:equal)

    plt2 = contour(range(xmin, xmax, length=100), range(ymin, ymax, length=100),
        [func([xi, yi]) for xi in range(xmin, xmax, length=100), yi in
range(ymin, ymax, length=100)],
        levels=30, title="Steepest Descent", aspect_ratio=:equal)

    plt3 = contour(range(xmin, xmax, length=100), range(ymin, ymax, length=100),
        [func([xi, yi]) for xi in range(xmin, xmax, length=100), yi in
range(ymin, ymax, length=100)],
        levels=30, title="Conjugate Gradient", aspect_ratio=:equal)

    # Траектория метода градиентного спуска (Gradient Descent)
    if !isempty(history_gd)
        traj_x_gd = [p[1] for p in history_gd]
        traj_y_gd = [p[2] for p in history_gd]
        plot!(plt1, traj_x_gd, traj_y_gd, marker=:square, color=:green,
linewidth=2, label="Gradient Descent")
    end
end

```

```

else
    println("Ошибка: пустая история для метода градиентного спуска")
end

# Траектория метода наискорейшего спуска (Steepest Descent)
if !isempty(history_sd)
    traj_x_sd = [p[1] for p in history_sd]
    traj_y_sd = [p[2] for p in history_sd]
    plot!(plt2, traj_x_sd, traj_y_sd, marker=:circle, color=:red, linewidth=2,
label="Steepest Descent")
else
    println("Ошибка: пустая история для метода наискорейшего спуска")
end

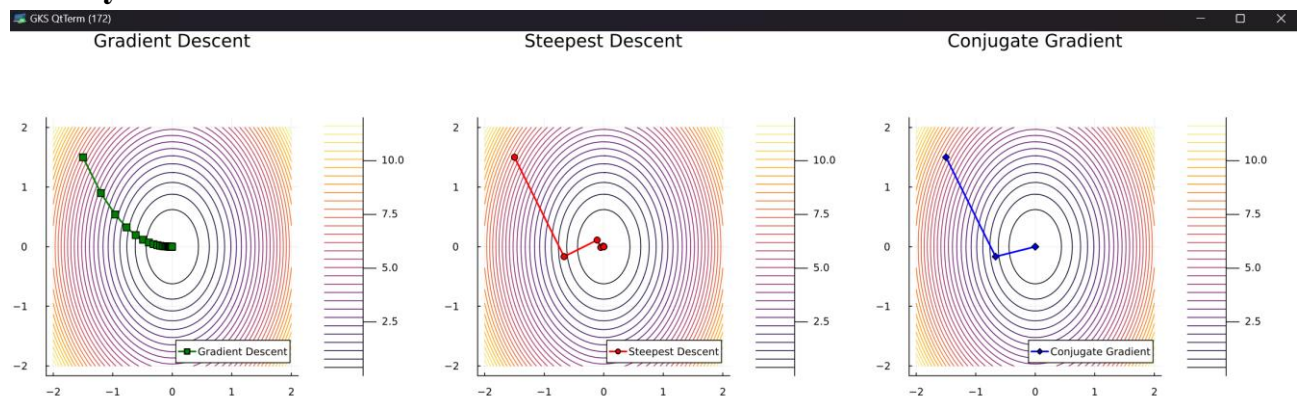
# Траектория метода сопряженных градиентов (Conjugate Gradient)
if !isempty(history_cg)
    traj_x_cg = [p[1] for p in history_cg]
    traj_y_cg = [p[2] for p in history_cg]
    plot!(plt3, traj_x_cg, traj_y_cg, marker=:diamond, color=:blue,
linewidth=2, label="Conjugate Gradient")
else
    println("Ошибка: пустая история для метода сопряженных градиентов")
end

# --- Отображение трех графиков на одном полотне ---
display(plot(plt1, plt2, plt3, layout=(1,3), size=(1500, 500)))
end

# Запуск эксперимента
optimize_func(target_quadratic, "Минимизация квадратичной функции")
readline()

```

3. Результаты



===== Минимизация квадратичной функции =====

Метод сошелся по критериям остановки на 27 итерации

Метод сошелся по градиенту на 11 итерации

Метод сошелся по изменениям координат на 4 итерации

Gradient Descent: $k = 27$ $x_{\min} = [-0.004538456711940925, -2.4412655482112337e-6]$ $f(x_{\min}) = 2.0597601245716587e-5$

Steepest Descent: $k = 11$ $x_{\min} = [-1.6117663123145467e-6, -6.480540234462138e-6]$ $f(x_{\min}) = 8.659259410647719e-11$

Conjugate Gradient: $k = 4$ $x_{\min} = [-1.670250051067889e-6, -5.397706541574913e-7]$ $f(x_{\min}) = 3.372439951271498e-12$

=====

4. Выводы

В ходе лабораторной работы были реализованы и протестированы три метода градиентной оптимизации:

1. Метод градиентного спуска (Gradient Descent, GD)

- Использует фиксированный шаг α , который уменьшается, если функция не убывает.
- Сильная зависимость от выбора шага α .
- Медленная сходимость на сложных функциях (например, на функции Розенброка).

2. Метод наискорейшего спуска (Steepest Descent, SD)

- Оптимальный шаг α вычисляется методом золотого сечения.
- Улучшенная сходимость по сравнению с обычным градиентным спуском.
- Долгие вычисления из-за дополнительной одномерной оптимизации на каждом шаге.

3. Метод сопряжённых градиентов (Conjugate Gradient, CG)

- Улучшает стандартный градиентный спуск за счёт использования направлений, учитывающих прошлые итерации.
- Самая быстрая сходимость на квадратичных и гладких нелинейных функциях.
- Минимальное число итераций по сравнению с другими методами.